

API명세서_250711

모든 엔드포인트에 대해

- 기본 정보 – Method · URL · 설명
- 요청 파라미터 – 필수 여부·타입·설명 (Query / Body 구분)
- 요청 예시 – 완전한 `curl` 명령
- 응답 파라미터 – 필드·타입·설명
- 성공 응답 예시
- 실패 응답 예시 (가능한 경우)

목차

#	엔드포인트	설명
1	/rag/	RAG 상태 확인
2	/rag/insert	문서 삽입
3	/rag/insert/raw	문서 원본 삽입
4	/rag/search	문서 검색
5	/rag/delete	문서 삭제
6	/rag/document	문서·패시지 조회
7	/rag/domains	도메인 목록 조회
8	/rag/domains/delete	도메인 삭제
9	/rag/data/show	컬렉션 정보 조회
10	/reranker/health	Reranker 상태
11	/reranker/rerank	단건 재랭킹 (FlashRank/MRC/하이브리드)
12	/prompt/health	Prompt 상태
13	/prompt/enhanced_search	RAG 검색 결과를 Reranker로 재랭킹 (LLM 요약 없음)
14	/prompt/chat	챗봇 응답
15	/prompt/models	모델 목록
16	/prompt/chatbot	RAG 챗봇 (멀티턴 대화)
17	/prompt/session/clear	세션 초기화
18	/prompt/session/cleanup	만료된 세션 정리
19	/prompt/session/list	세션 목록 조회
20	/prompt/session/get	세션 내용 조회

모든 URL 는 <https://fai-rag.fingerservice.co.kr> 기준입니다.

1. /rag/

기본 정보

항목	내용
Method	GET
URL	/rag/
설명	RAG FastCGI 서비스 헬스 체크

요청 파라미터

없음

요청 예시

```
curl -X GET https://fai-rag.fingerservice.co.kr/rag/
```

응답 파라미터

필드	Type	설명
message	String	상태 메시지

성공 응답 예시

```
{ "message": "Hello, FastCGI is working!" }
```

2. /rag/insert

기본 정보

항목	내용
Method	POST
URL	/rag/insert
Content-Type	application/json
설명	문서를 Milvus 컬렉션에 삽입

요청 파라미터 (Body)

필드	필수	Type	설명
documents	Y	Array	삽입할 문서 배열
ignore	N	Boolean	중복 문서 무시 여부 (기본값: true)

각 문서 객체의 구조:

필드	필수	Type	설명
domain	Y	String	컬렉션 이름 (예: news)
title	Y	String	문서 제목
author	Y	String	작성자/기관
text	Y	String	본문
info	N	Object	{ press_num, url }
tags	Y	Object	{ date(YYYYMMDD), user }

요청 예시

```
curl -X POST https://fai-rag.fingerservice.co.kr/rag/insert \
-H "Content-Type: application/json" \
-d '{
  "documents": [
    {
      "domain": "news",
      "title": "메타버스 뉴스",
      "author": "삼성전자",
      "text": "메타버스는 비대면 시대 뜨거운 화두로 떠올랐다...",
      "info": { "press_num": "비즈니스 워치", "url": "http://example.com/news/1"
    },
    "tags": { "date": "20240315", "user": "admin" }
  ],
  "ignore": true
}'
```

응답 파라미터

필드	Type	설명
status	String	전체 처리 상태 ("success", "partial_success", "partial_error", "error")
message	String	처리 결과 메시지
status_counts	Object	상태별 처리 건수 (success , skipped , error)
results	Array	각 문서별 처리 결과

성공 응답 예시

```
{
  "status": "success",
  "message": "총 3개 문서 중 2개 성공, 1개 건너뛴",
  "status_counts": {
    "success": 2,
    "skipped": 1,
    "error": 0
  },
  "results": [
    {
      "status": "success",
      "message": "문서가 성공적으로 저장되었습니다.",
      "doc_id": "1234567890abcdef...",
      "raw_doc_id": "20240315-메타버스 뉴스-삼성전자",
      "domain": "news",
      "title": "메타버스 뉴스"
    },
    {
      "status": "skipped",
      "message": "이미 존재하는 문서로 건너뛰었습니다.",
      "doc_id": "abcdef1234567890...",
      "raw_doc_id": "20240315-AI 뉴스-LG전자",
      "domain": "news",
      "title": "AI 뉴스"
    }
  ]
}
```

실패 응답 예시

```
{
  "status": "error",
  "message": "요청 본문이 비어있습니다.",
  "error_code": "F000001"
}
```

3. /rag/insert/raw

기본 정보

항목	내용
Method	POST
URL	/rag/insert/raw

항목	내용
Content-Type	application/json
설명	텍스트를 분할하지 않고 그대로 저장

요청 파라미터 (Body)

필드	필수	Type	설명
documents	Y	Array	삽입할 문서 배열
ignore	N	Boolean	중복 문서 처리 (기본값: true)

각 문서 객체의 구조:

필드	필수	Type	설명
doc_id	Y	String	사용자 지정 문서 ID
passage_id	Y	Integer	사용자 지정 패시지 ID
domain	Y	String	컬렉션 이름
title	Y	String	문서 제목
author	Y	String	작성자/기관
text	Y	String	본문
info	N	Object	{ press_num, url }
tags	Y	Object	{ date(YYYYMMDD), user }

요청 예시

```
curl -X POST https://fai-rag.fingerservice.co.kr/rag/insert/raw \
-H "Content-Type: application/json" \
-d '{
  "documents": [
    {
      "doc_id": "unique_document_id",
      "passage_id": 1,
      "domain": "news",
      "title": "메타버스 뉴스",
      "author": "삼성전자",
      "text": "메타버스는 비대면 시대 뜨거운 화두로 떠올랐다...",
      "info": { "press_num": "비즈니스 워치", "url": "http://example.com/news/1"
    },
    "tags": { "date": "20240315", "user": "admin" }
  ],
  "ignore": true
}'
```

응답 파라미터

필드	Type	설명
status	String	전체 처리 상태 ("success", "partial_success", "partial_error", "error")
message	String	처리 결과 메시지
status_counts	Object	상태별 처리 건수 (success, updated, skipped, error)
results	Array	각 문서별 처리 결과

성공 응답 예시

```
{
  "status": "success",
  "message": "총 3개 문서 중 2개 성공, 1개 업데이트, 0개 건너뛴, 0개 실패",
  "status_counts": {
    "success": 2,
    "updated": 1,
    "skipped": 0,
    "error": 0
  },
  "results": [
    {
      "status": "success",
      "message": "문서가 성공적으로 저장되었습니다.",
      "doc_id": "unique_document_id",
      "passage_id": 1,
      "domain": "news",
      "title": "메타버스 뉴스"
    }
  ]
}
```

4. /rag/search

기본 정보

항목	내용
Method	POST
URL	/rag/search
Content-Type	application/json
설명	Milvus에서 유사 문서 검색

요청 파라미터 (Body)

필드	필수	Type	기본	설명
query_text	Y	String	-	검색어
top_k	N	Integer	5	검색 결과 수
domains	N	Array	[]	도메인 필터 (복수 지정 가능, 빈 배열이거나 없는 경우 모든 도메인에서 검색)
author	N	String	-	작성자 필터
start_date	N	String	-	시작일 YYYYMMDD
end_date	N	String	-	종료일 YYYYMMDD
title	N	String	-	제목 검색
info_filter	N	Object	-	info 필드 필터링
tags_filter	N	Object	-	tags 필드 필터링

요청 예시

```
curl -X POST https://fai-rag.fingerservice.co.kr/rag/search \
-H "Content-Type: application/json" \
-d '{
  "query_text": "메타버스",
  "top_k": 5,
  "domains": ["news", "test"],
  "start_date": "20240301",
  "end_date": "20240315"
}'
```

응답 파라미터

필드	Type	설명
result_code	String	F000000 성공 등
message	String	결과 메시지
search_params	Object	적용된 검색 파라미터
total_results	Integer	전체 검색 결과 수
returned_results	Integer	반환된 결과 수
search_result	Array	검색 결과 배열
performance	Object	성능 메트릭 정보

각 검색 결과 객체의 구조:

필드	Type	설명
doc_id	String	문서 ID
raw_doc_id	String	원본 문서 ID
passage_id	Integer	패시지 ID
domain	String	도메인명
title	String	제목
author	String	작성자
text	String	본문 내용
info	Object	추가 정보
tags	Object	태그 정보
score	Float	유사도 점수

performance 객체의 구조:

필드	Type	설명
total_time	Float	전체 처리 시간(초)
domain_details	Object	도메인별 처리 시간 정보

성공 응답 예시

```
{
  "result_code": "F000000",
  "message": "검색이 성공적으로 완료되었습니다.",
  "search_params": {
    "query_text": "메타버스",
    "domains": ["news", "test"],
    "top_k": 5,
    "filters": {
      "date_range": {
        "start": "20240301",
        "end": "20240315"
      }
    }
  },
  "total_results": 10,
  "returned_results": 5,
  "search_result": [
    {
      "doc_id": "109f405744d2f1e0eccb880c70c6c6e9...",
      "raw_doc_id": "20240315-메타버스 뉴스-삼성전자",
      "passage_id": 1,
```



```
    "domain": "news",
    "title": "메타버스 뉴스",
    "author": "삼성전자",
    "text": "메타버스는 비대면 시대 뜨거운 화두로 떠올랐다...",
    "info": {
      "press_num": "비즈니스 워치",
      "url": "http://example.com/news/1"
    },
    "tags": {
      "date": "20240315",
      "user": "admin"
    },
    "score": 0.95
  }
],
"performance": {
  "total_time": 0.153,
  "domain_details": {
    "news": {
      "time": 0.089,
      "results_count": 7
    },
    "test": {
      "time": 0.064,
      "results_count": 3
    }
  }
}
```

실패 응답 예시

```
{
  "result_code": "F000001",
  "message": "검색어(query_text)는 필수 입력값입니다.",
  "search_result": null
}
```

5. /rag/delete

기본 정보

항목	내용
Method	DELETE
URL	/rag/delete
설명	문서 삭제

요청 파라미터 (Query)

이름	필수	Type	설명
doc_id	Y	String	문서 ID (원본 raw_doc_id 또는 해시된 doc_id 모두 사용 가능)
domain	Y	String	삭제할 도메인

doc_id 처리 방식

- 원본 문서 ID(raw_doc_id) 또는 해시된 문서 ID(doc_id) 모두 사용 가능
- 시스템이 자동으로 ID 형식을 감지하여 처리
- 해시된 ID의 경우: 64자 길이의 16진수 문자열

요청 예시

```
curl -X DELETE "https://fai-rag.fingerservice.co.kr/rag/delete?doc_id=20240315-메타버스-뉴스&domain=news"
```

응답 파라미터

필드	Type	설명
result_code	String	결과 코드 ("F000000" 성공 등)
message	String	처리 결과 메시지
doc_id	String	삭제된 문서 ID
domain	String	삭제된 도메인

성공 응답 예시

```
{
  "result_code": "F000000",
  "message": "문서가 성공적으로 삭제되었습니다.",
  "doc_id": "20240315-메타버스-뉴스",
  "domain": "news"
}
```

실패 응답 예시

```
{
  "error": "domain is required",
  "message": "도메인(domain)은 필수 입력값입니다."
}
```

6. /rag/document

기본 정보

항목	내용
Method	POST
URL	<code>/rag/document</code>
Content-Type	<code>application/json</code>
설명	특정 문서 혹은 패시지 조회

요청 파라미터 (Body)

필드	필수	Type	설명
doc_id	Y	String	문서 ID (원본 raw_doc_id 또는 해시된 doc_id 모두 사용 가능)
domains	Y	Array	검색할 도메인 배열
passage_id	N	Integer	패시지 ID (특정 패시지만 조회 시)

doc_id 처리 방식

- 원본 문서 ID(raw_doc_id) 또는 해시된 문서 ID(doc_id) 모두 사용 가능
- 시스템이 자동으로 ID 형식을 감지하여 처리
- 해시된 ID의 경우: 64자 길이의 16진수 문자열
- 응답에는 항상 두 가지 ID가 모두 포함됨 (doc_id, raw_doc_id)

요청 예시

```
curl -X POST https://fai-rag.fingerservice.co.kr/rag/document \
-H "Content-Type: application/json" \
-d '{
  "doc_id": "20240315-메타버스-뉴스",
  "domains": ["news", "test"],
  "passage_id": 1
}'
```

응답 파라미터

필드	Type	설명
doc_id	String	해시된 문서 ID
raw_doc_id	String	원본 문서 ID
domain_results	Object	도메인별 결과

도메인별 결과 객체의 구조:

필드	Type	설명
doc_id	String	해시된 문서 ID
raw_doc_id	String	원본 문서 ID
domain	String	도메인명
title	String	문서 제목
author	String	작성자
info	Object	추가 정보
tags	Object	태그 정보
passages	Array	패시지 목록

패시지 객체의 구조:

필드	Type	설명
passage_id	Integer	패시지 ID
text	String	패시지 내용
position	Integer	패시지 순서

성공 응답 예시 (전체 문서 조회)

```
{
  "doc_id": "해시된_문서_ID",
  "raw_doc_id": "원본_문서_ID",
  "domain_results": {
    "news": {
      "doc_id": "해시된_문서_ID",
      "raw_doc_id": "원본_문서_ID",
      "domain": "news",
      "title": "메타버스 뉴스",
      "author": "삼성전자",
      "info": {
        "press_num": "비즈니스 워치",
        "url": "http://example.com/news/1"
      },
      "tags": {
        "date": "20240315",
        "user": "admin"
      },
      "passages": [
        {
          "passage_id": 1,
          "text": "메타버스는...",
          "position": 1
        }
      ]
    }
  }
}
```

```

    ]
  },
  "test": {
    "doc_id": "해시된_문서_ID",
    "raw_doc_id": "원본_문서_ID",
    "domain": "test",
    "title": "메타버스 테스트",
    "author": "LG전자",
    "info": { ... },
    "tags": { ... },
    "passages": [ ... ]
  }
}

```

성공 응답 예시 (특정 패시지 조회)

```

{
  "doc_id": "20240315-메타버스-뉴스",
  "domains": ["news", "test"],
  "title": "메타버스 뉴스",
  "passage_id": 1,
  "text": "메타버스는...",
  "position": 1
}

```

실패 응답 예시 (문서 없음)

```

{
  "error": "Document not found",
  "doc_id": "20230101-존재-하지-않음",
  "domains": ["news", "test"],
  "message": "요청하신 문서를 찾을 수 없습니다."
}

```

실패 응답 예시 (패시지 없음)

```

{
  "error": "Passage not found",
  "doc_id": "20240315-메타버스-뉴스",
  "passage_id": 999,
  "domains": ["news", "test"],
  "message": "요청하신 패시지를 찾을 수 없습니다."
}

```

7. /rag/domains

기본 정보

항목	내용
Method	GET
URL	/rag/domains
설명	시스템에 등록된 모든 도메인(컬렉션) 목록 조회

요청 파라미터

없음

요청 예시

```
curl -X GET https://fai-rag.fingerservice.co.kr/rag/domains
```

응답 파라미터

필드	Type	설명
result_code	String	S000000 성공 등
message	String	결과 메시지
domains	Array	도메인(컬렉션) 정보 배열

각 도메인 정보 객체의 구조:

필드	Type	설명
name	String	도메인(컬렉션) 이름
entity_count	Integer	도메인 내 엔티티 수
document_count	Integer/String	도메인 내 고유 문서 수 (계산 불가 시 "계산 불가" 문자열)

성공 응답 예시

```
{
  "result_code": "S000000",
  "message": "도메인 목록을 성공적으로 조회했습니다.",
  "domains": [
    {
      "name": "news",
      "entity_count": 1250,
      "document_count": 450
    },
  ],
}
```

```
{
  {
    "name": "test",
    "entity_count": 42,
    "document_count": 15
  }
}
```

실패 응답 예시

```
{
  "result_code": "F000010",
  "message": "도메인 목록 조회에 실패했습니다: 연결 오류",
  "domains": []
}
```

8. /rag/domains/delete

기본 정보

항목	내용
Method	POST
URL	/rag/domains/delete
Content-Type	application/json
설명	지정된 도메인(컬렉션)을 모든 엔티티와 함께 완전히 삭제

요청 파라미터 (Body)

필드	필수	Type	설명
domains	Y	String/Array	삭제할 도메인 이름 (단일 문자열 또는 문자열 배열)

요청 예시

```
curl -X POST https://fai-rag.fingerservice.co.kr/rag/domains/delete \
-H "Content-Type: application/json" \
-d '{
  "domains": ["test_domain", "old_collection"]
}'
```

응답 파라미터

필드	Type	설명
result_code	String	S000000 성공 등
status	String	전체 처리 상태 ("success", "error", "partial", "not_found")
message	String	처리 결과 메시지
results	Array	각 도메인별 처리 결과

각 도메인 처리 결과의 구조:

필드	Type	설명
name	String	도메인 이름
status	String	상태 ("success", "error", "not_found")
entity_count	Integer/String	삭제된 엔티티 수 (또는 "알 수 없음")
message	String	처리 결과 메시지

성공 응답 예시

```
{
  "result_code": "S000000",
  "status": "success",
  "message": "총 2개 도메인 중 2개 삭제 성공, 0개 실패, 0개 없음",
  "results": [
    {
      "name": "test_domain",
      "status": "success",
      "entity_count": 120,
      "message": "도메인이 성공적으로 삭제되었습니다."
    },
    {
      "name": "old_collection",
      "status": "success",
      "entity_count": 35,
      "message": "도메인이 성공적으로 삭제되었습니다."
    }
  ]
}
```

실패 응답 예시 (존재하지 않는 도메인)

```
{
  "result_code": "F000005",
  "status": "not_found",
  "message": "총 2개 도메인 중 0개 삭제 성공, 0개 실패, 2개 없음",
  "results": [
```



```
{
  {
    "name": "unknown_domain",
    "status": "not_found",
    "message": "존재하지 않는 도메인입니다."
  },
  {
    "name": "missing_collection",
    "status": "not_found",
    "message": "존재하지 않는 도메인입니다."
  }
}
```

실패 응답 예시 (시스템 오류)

```
{
  "result_code": "F000010",
  "message": "도메인 삭제에 실패했습니다: 연결 오류",
  "status": "error"
}
```

9. /rag/data/show

기본 정보

항목	내용
Method	GET
URL	/rag/data/show

요청 파라미터 (Query)

이름	필수	Type	설명
collection_name	Y	String	컬렉션 이름

요청 예시

```
curl -G https://fai-rag.fingerservice.co.kr/rag/data/show --data-urlencode "collection_name=news"
```

응답 파라미터 (정상)

필드	Type	설명
----	------	----

필드	Type	설명
schema	Object	컬렉션 스키마
partition_names	Array	파티션 목록
partition_nums	Object	파티션 → 엔티티 수

성공 응답 예시

```
{
  "schema": { "fields": [ { "name": "doc_id", "type": "VARCHAR" } ] },
  "partition_names": [ "p1" ],
  "partition_nums": { "p1": 100 }
}
```

실패 응답 예시 (없는 컬렉션 – HTTP 200)

```
{
  "error": "유효한 Collection 이름을 입력해야 합니다.",
  "collection list": ["news", "description"]
}
```

10. /reranker/health

기본 정보

항목	내용
Method	GET
URL	/reranker/health
설명	Reranker 헬스 체크

요청 파라미터

없음

요청 예시

```
curl -X GET https://fai-rag.fingerservice.co.kr/reranker/health
```

응답 파라미터

필드	Type	설명
status	String	"ok"
service	String	"reranker"

성공 응답 예시

```
{ "status": "ok", "service": "reranker" }
```

11. /reranker/rerank

기본 정보

항목	내용
Method	POST
URL	/reranker/rerank
Content-Type	application/json
설명	단일 쿼리와 결과 목록을 재랭킹

요청 파라미터

Query:

이름	필수	Type	기본값	설명
top_k	N	Integer	-	반환할 최대 결과 수
type	N	String	"auto"	재랭킹 방식 ("flashrank", "mrc", "hybrid", "auto")
weight_flashrank	N	Float	-	FlashRank 점수 가중치
weight_mrc	N	Float	-	MRC 점수 가중치
weight_original	N	Float	-	원본 검색 점수 가중치

Body:

필드	필수	Type	설명
query	Y	String	검색 쿼리
results	Y	Array	재랭킹할 문서 배열
total	N	Integer	전체 결과 수
reranked	N	Boolean	이미 재랭킹 되었는지 여부

각 결과 객체의 구조:

필드	필수	Type	설명
passage_id	N	Any	패시지 ID
doc_id	N	String	문서 ID
text	Y	String	패시지 텍스트 내용
score	N	Float	원본 점수
position	N	Integer	원본 위치
metadata	N	Object	메타데이터 객체

metadata 객체의 구조:

필드	필수	Type	설명
title	N	String	문서 제목
author	N	String	작성자
tags	N	Object	태그 정보 (예: date)
doc_id	N	String	문서 ID (중복 가능)
original_score	N	Float	원본 점수

요청 예시

```
curl -X POST "https://fai-rag.fingerservice.co.kr/reranker/rerank?
top_k=3&type=hybrid&weight_flashrank=0.3&weight_mrc=0.5&weight_original=0.2" \
-H "Content-Type: application/json" \
-d '{
  "query": "인공지능이란 무엇인가?",
  "results": [
    {
      "passage_id": 1,
      "doc_id": "doc001",
      "text": "인공지능(AI)은 인간의 학습, 추론, 지각, 문제 해결 능력 등을 컴퓨터 프
로그래밍으로 구현한 기술이다.",
      "score": 0.85,
      "position": 0,
      "metadata": {
        "title": "인공지능 개론",
        "author": "AI연구소",
        "tags": {"date": "20240315"},
        "original_score": 0.85
      }
    },
    {
      "passage_id": 2,
      "doc_id": "doc002",
```

```
      "text": "머신러닝은 인공지능의 한 분야로, 컴퓨터가 데이터로부터 학습하여 패턴을  
      찾아내는 방법론이다.",  
      "score": 0.75,  
      "position": 1,  
      "metadata": {  
        "title": "머신러닝 기초",  
        "author": "ML 연구소",  
        "tags": {"date": "20240310"},  
        "original_score": 0.75  
      }  
    },  
    "total": 2,  
    "reranked": false  
  }'
```

응답 파라미터

필드	Type	설명
query	String	요청한 검색 쿼리
results	Array	재랭킹된 결과 배열
total	Integer/null	결과 총 개수
reranked	Boolean	재랭킹 완료 여부 (true: 재랭킹 성공)
reranker_type	String	사용된 재랭킹 방식 ("flashrank", "mrc", "hybrid")
processing_time	Float	처리 소요 시간(초)
weights	Object	사용된 가중치 정보
flashrank_time	Float	FlashRank 처리 시간(초) (하이브리드 모드에서만)
mrc_time	Float	MRC 처리 시간(초) (하이브리드 모드에서만)
mrc_weight	Float	사용된 MRC 가중치 (하이브리드 모드에서만)

weights 객체의 구조:

필드	Type	설명
flashrank	Float	FlashRank 점수 가중치
mrc	Float	MRC 점수 가중치
original	Float	원본 검색 점수 가중치

각 결과 객체의 구조:

필드	Type	설명
passage_id	Any	패시지 ID

필드	Type	설명
doc_id	String	문서 ID
text	String	패시지 텍스트 내용
score	Float	최종 재랭킹 점수
position	Integer	원본 위치
title	String	문서 제목 (있는 경우)
author	String	작성자 (있는 경우)
domain	String	도메인 (있는 경우)
mrc_answer	String	MRC 모델이 추출한 답변 텍스트 (MRC/하이브리드 모드에서만)
mrc_char_ids	Array	답변의 시작/끝 문자 인덱스 [start, end] (MRC/하이브리드 모드에서만)
mrc_score	Float	MRC 모델 점수 (MRC/하이브리드 모드에서만)
flashrank_score	Float	FlashRank 점수 (FlashRank/하이브리드 모드에서만)
hybrid_score	Float	하이브리드 최종 점수 (하이브리드 모드에서만)
original_score	Float	원본 검색 점수
metadata	Object	메타데이터 객체 (title, author, tags, 점수 정보 포함)

성공 응답 예시

```
{
  "query": "인공지능이란 무엇인가?",
  "results": [
    {
      "passage_id": 1,
      "doc_id": "doc001",
      "text": "인공지능(AI)은 인간의 학습, 추론, 지각, 문제 해결 능력 등을 컴퓨터 프로그램으로 구현한 기술이다.",
      "score": 0.9650318562984466,
      "position": 0,
      "title": "인공지능 개론",
      "author": "AI연구소",
      "domain": "tech",
      "mrc_answer": "인간의 학습, 추론, 지각, 문제 해결 능력 등을 컴퓨터 프로그램으로 구현한 기술",
      "mrc_char_ids": [10, 55],
      "mrc_score": 0.9698712229728699,
      "flashrank_score": 0.9537400007247925,
      "hybrid_score": 0.9650318562984466,
      "original_score": 0.85,
      "metadata": {
        "title": "인공지능 개론",
        "author": "AI연구소",
```

```

    "tags": {"date": "20240315"},
    "flashrank_score": 0.9537400007247925,
    "mrc_score": 0.9698712229728699,
    "original_score": 0.85
  }
},
{
  "passage_id": 2,
  "doc_id": "doc002",
  "text": "머신러닝은 인공지능의 한 분야로, 컴퓨터가 데이터로부터 학습하여 패턴을
  찾아내는 방법론이다.",
  "score": 0.3672780990600586,
  "position": 1,
  "title": "머신러닝 기초",
  "author": "ML연구소",
  "domain": "tech",
  "mrc_answer": "컴퓨터가 데이터로부터 학습하여 패턴을 찾아내는 방법론",
  "mrc_char_ids": [19, 48],
  "mrc_score": 0.3194928467273712,
  "flashrank_score": 0.4787770211696625,
  "hybrid_score": 0.3672780990600586,
  "original_score": 0.75,
  "metadata": {
    "title": "머신러닝 기초",
    "author": "ML연구소",
    "tags": {"date": "20240310"},
    "flashrank_score": 0.4787770211696625,
    "mrc_score": 0.3194928467273712,
    "original_score": 0.75
  }
}
],
"total": 2,
"reranked": true,
"reranker_type": "hybrid",
"processing_time": 1.0239102840423584,
"weights": {
  "flashrank": 0.3,
  "mrc": 0.5,
  "original": 0.2
},
"flashrank_time": 0.0,
"mrc_time": 0.3780794143676758,
"mrc_weight": 0.5
}

```

실패 응답 예시

```

{
  "error": "No JSON data provided"
}

```

12. /prompt/health

기본 정보

항목	내용
Method	GET
URL	/prompt/health
설명	Prompt-Backend 헬스 체크

요청 파라미터

없음

요청 예시

```
curl -X GET https://fai-rag.fingerservice.co.kr/prompt/health
```

```
### 성공 응답 예시
```json
{
 "status": "ok",
 "timestamp": "2025-04-22T12:34:56Z",
 "service": "prompt-backend"
}
```

## 13. /prompt/enhanced\_search

### 기본 정보

항목	내용
Method	<b>POST</b>
URL	<b>/prompt/enhanced_search</b>
Content-Type	<b>application/json</b>
설명	RAG 검색 결과를 Reranker로 재랭킹 (LLM 요약 없음)

### 요청 파라미터 (Body)



필드	필수	Type	설명
query	Y	String	검색 쿼리
top_m	N	Integer	RAG 검색 결과 최대 수 (기본값: config의 search_top)
top_n	N	Integer	Reranker 결과 최대 수 (기본값: config의 rerank_top)
threshold	N	Float	재랭킹 점수 임계치 (기본값: 0.1) - 이 값보다 낮은 점수의 결과는 필터링됨
domain	N	String	단일 도메인 필터 (지정하지 않으면 모든 도메인에서 검색)
domains	N	Array	복수 도메인 필터 (빈 배열이거나 없는 경우 모든 도메인에서 검색)
author	N	String	작성자 필터
start_date	N	String	시작일 <span>YYYYMMDD</span>
end_date	N	String	종료일 <span>YYYYMMDD</span>
title	N	String	제목 검색
info_filter	N	Object	<span>info</span> 필드 필터링
tags_filter	N	Object	<span>tags</span> 필드 필터링
weight_flashrank	N	Float	FlashRank 가중치 (기본값: 0.5)
weight_mrc	N	Float	MRC 가중치 (기본값: 0.3)
weight_original	N	Float	원본 점수 가중치 (기본값: 0.2)

요청 예시

```
curl -X POST https://fai-rag.fingerservice.co.kr/prompt/enhanced_search \
-H "Content-Type: application/json" \
-d '{
 "query": "메타버스 최신 동향",
 "top_m": 50,
 "top_n": 10,
 "threshold": 0.2,
 "domain": "news",
 "start_date": "20240301",
 "end_date": "20240331",
 "weight_flashrank": 0.5,
 "weight_mrc": 0.3,
 "weight_original": 0.2
}'
```

응답 파라미터

필드	Type	설명
----	------	----

필드	Type	설명
query	String	요청한 쿼리
top_m	Integer	요청한 RAG 검색 결과 최대 수
top_n	Integer	요청한 Reranker 결과 최대 수
threshold	Float	적용된 임계치 값
search_count	Integer	실제 검색된 문서 수
reranked_count	Integer	실제 재랭킹된 문서 수
filtered_count	Integer	임계치 필터링 후 남은 문서 수
results	Array	재랭킹된 결과 배열
processing_time	Float	처리 소요 시간(초)
weight_flashrank	Float	사용된 FlashRank 가중치
weight_mrc	Float	사용된 MRC 가중치
weight_original	Float	사용된 원본 점수 가중치

각 결과 항목의 구조:

필드	Type	설명
passage_id	Any	패시지 ID
doc_id	String	문서 ID
text	String	패시지 텍스트 내용
score	Float	점수
rerank_score	Float	재랭킹 점수
rerank_position	Integer	재랭킹 후 위치
title	String	문서 제목
author	String	작성자
domain	String	문서 도메인
tags	Object	태그 정보 (date 등)
info	Object	추가 정보 (press_num, url 등)

성공 응답 예시

```
{
 "query": "메타버스 최신 동향",
 "top_m": 50,
 "top_n": 10,
```

```

"threshold": 0.2,
"search_count": 35,
"reranked_count": 10,
"filtered_count": 8,
"results": [
 {
 "passage_id": 1,
 "doc_id": "20240310-가상현실-동향",
 "text": "가상현실 기술은 게임뿐 아니라 교육, 의료 등 다양한 분야로 확장되고 있
다...",
 "score": 0.98,
 "rerank_score": 0.98,
 "rerank_position": 0,
 "title": "가상현실 동향",
 "author": "LG전자",
 "domain": "news",
 "tags": {
 "date": "20240310"
 },
 "info": {
 "press_num": "IT뉴스",
 "url": "http://example.com/vr-news"
 }
 },
 {
 "passage_id": 0,
 "doc_id": "20240315-메타버스-뉴스",
 "text": "메타버스는 비대면 시대 뜨거운 화두로 떠올랐다...",
 "score": 0.95,
 "rerank_score": 0.95,
 "rerank_position": 1,
 "title": "메타버스 뉴스",
 "author": "삼성전자",
 "domain": "tech",
 "tags": {
 "date": "20240315"
 },
 "info": {
 "press_num": "비즈니스 위치",
 "url": "http://example.com/metaverse-news"
 }
 }
],
"processing_time": 0.153,
"weight_flashrank": 0.5,
"weight_mrc": 0.3,
"weight_original": 0.2
}

```

## 실패 응답 예시

```
{
 "error": "쿼리가 필요합니다"
}
```

## 14. /prompt/chat

### 기본 정보

항목	내용
Method	<b>POST</b>
URL	<code>/prompt/chat</code>
Content-Type	<code>application/json</code>
설명	간단한 Q&A 챗봇

### 요청 파라미터 (Body)

이름	필수	Type	설명
query	Y	String	질문 내용
model	N	String	사용할 모델 (기본값: 서버 설정)
stream	N	Boolean	스트리밍 모드 활성화 여부 (기본값: false)

### 요청 예시 (일반 모드)

```
curl -X POST https://fai-rag.fingerservice.co.kr/prompt/chat \
-H "Content-Type: application/json" \
-d '{ "query": "메타버스란 무엇인가요?", "model": "llama2", "stream": false }'
```

### 요청 예시 (스트리밍 모드)

```
curl -X POST https://fai-rag.fingerservice.co.kr/prompt/chat \
-H "Content-Type: application/json" \
-H "Accept: text/event-stream" \
-d '{ "query": "메타버스란 무엇인가요?", "model": "llama2", "stream": true }'
```

### 성공 응답 예시 (일반 모드)

```
{
 "query": "메타버스란 무엇인가요?",
```

```
 "model": "llama2",
 "response": "메타버스는 가상과 현실이 융합된 디지털 공간입니다..."
 }
```

스트리밍 모드 응답

스트리밍 모드 활성화(`stream=true`) 시:

- 응답은 `text/event-stream` 형식으로 반환됩니다
- 응답은 생성되는 텍스트 조각들이 실시간으로 전송됩니다
- 클라이언트는 이를 순차적으로 수신하여 사용자에게 표시할 수 있습니다

실패 응답 예시

```
{ "error": "질문이 필요합니다" }
```

## 15. /prompt/models

기본 정보

항목	내용
Method	<b>GET</b>
URL	<code>/prompt/models</code>
설명	사용 가능한 LLM 모델 목록

요청 파라미터

없음

요청 예시

```
curl -X GET https://fai-rag.fingerservice.co.kr/prompt/models
```

```
성공 응답 예시
```json
{
  "models": ["llama2", "mistral", "gemma"],
  "default_model": "llama2",
  "total": 3
}
```

실패 응답 예시

```
{ "error": "모델 목록을 가져오는 중 오류가 발생했습니다" }
```

16. /prompt/chatbot

기본 정보

항목	내용
Method	POST
URL	<code>/prompt/chatbot</code>
Content-Type	<code>application/json</code>
설명	RAG 챗봇 API (멀티턴 대화)

요청 파라미터 (Body)

이름	필수	Type	설명
query	Y	String	질문 내용
session_id	Y	String	세션 ID (대화 기록 유지용)
model	N	String	사용할 모델 (기본값: 서버 설정)
stream	N	Boolean	스트리밍 모드 활성화 여부 (기본값: false)
domains	N	Array	검색할 도메인 배열
domain	N	String	검색할 단일 도메인
author	N	String	작성자 필터
start_date	N	String	시작일 <code>YYYYMMDD</code>
end_date	N	String	종료일 <code>YYYYMMDD</code>
title	N	String	제목 검색
info_filter	N	String	정보 필터
tags_filter	N	String	태그 필터
weight_flashrank	N	Float	FlashRank 가중치 (기본값: 0.5)
weight_mrc	N	Float	MRC 가중치 (기본값: 0.3)
weight_original	N	Float	원본 점수 가중치 (기본값: 0.2)

요청 예시 (일반 모드)

```
curl -X POST https://fai-rag.fingerservice.co.kr/prompt/chatbot \
-H "Content-Type: application/json" \
-d '{
  "query": "메타버스란 무엇인가요?",
  "session_id": "user123_session",
  "model": "mistral",
  "domain": "tech",
  "weight_flashrank": 0.5,
  "weight_mrc": 0.3,
  "weight_original": 0.2
}'
```

요청 예시 (스트리밍 모드)

```
curl -X POST https://fai-rag.fingerservice.co.kr/prompt/chatbot \
-H "Content-Type: application/json" \
-H "Accept: text/event-stream" \
-d '{
  "query": "메타버스란 무엇인가요?",
  "session_id": "user123_session",
  "model": "mistral",
  "stream": true,
  "weight_flashrank": 0.5,
  "weight_mrc": 0.3,
  "weight_original": 0.2
}'
```

성공 응답 예시 (일반 모드)

```
```json
{
 "query": "메타버스란 무엇인가요?",
 "session_id": "user123_session",
 "model": "mistral",
 "response": "메타버스는 가상과 현실이 융합된 디지털 공간입니다. 사용자들은 아바타를 통해 이 공간에서 상호작용하고, 다양한 활동을 할 수 있습니다. 최근에는 게임, 교육, 비즈니스 미팅 등 다양한 분야에서 활용되고 있으며, 특히 코로나19 이후 비대면 환경에서 더욱 주목 받고 있습니다."
}
```

## 스트리밍 모드 응답

스트리밍 모드 활성화(`stream=true`) 시:

- 응답은 `text/event-stream` 형식으로 반환됩니다
- 응답은 생성되는 텍스트 조각들이 실시간으로 전송됩니다
- 클라이언트는 이를 순차적으로 수신하여 사용자에게 표시할 수 있습니다

## 실패 응답 예시

```
{
 "error": "질문이 필요합니다"
}
```

또는

```
{
 "error": "세션 ID가 필요합니다"
}
```

---

## 17. /prompt/session/clear

### 기본 정보

항목	내용
Method	<b>POST</b>
URL	<code>/prompt/session/clear</code>
Content-Type	<code>application/json</code>
설명	특정 세션을 초기화 (대화 기록 삭제)

### 요청 파라미터 (Body)

이름	필수	Type	설명
session_id	Y	String	초기화할 세션 ID

### 요청 예시

```
curl -X POST https://fai-rag.fingerservice.co.kr/prompt/session/clear \
-H "Content-Type: application/json" \
-d '{
 "session_id": "user123_session"
}'
```

### 성공 응답 예시

```
{
 "status": "success",
}
```



```
{
 "message": "세션 user123_session가 초기화되었습니다"
}
```

### 실패 응답 예시

```
{
 "error": "세션 ID가 필요합니다"
}
```

---

## 18. /prompt/session/cleanup

### 기본 정보

항목	내용
Method	<b>POST</b>
URL	/prompt/session/cleanup
Content-Type	application/json
설명	만료된 모든 세션 파일 정리

### 요청 파라미터

없음

### 요청 예시

```
curl -X POST https://fai-rag.fingerservice.co.kr/prompt/session/cleanup \
-H "Content-Type: application/json"
```

### 성공 응답 예시

```
{
 "status": "success",
 "message": "5개의 만료된 세션이 정리되었습니다"
}
```

### 실패 응답 예시

```
{
 "error": "만료된 세션 정리 중 오류가 발생했습니다: 파일 접근 권한 없음"
}
```

```
}

```

## 19. /prompt/session/list

### 기본 정보

항목	내용
Method	<b>GET</b>
URL	<code>/prompt/session/list</code>
설명	모든 세션 목록 조회

### 요청 파라미터

없음

### 요청 예시

```
curl -X GET https://fai-rag.fingerservice.co.kr/prompt/session/list

```

```
성공 응답 예시
```json
{
  "sessions": [
    "user123_session",
    "user456_session",
    "admin_test_session"
  ],
  "count": 3
}

```

실패 응답 예시

```
{
  "error": "세션 목록 조회 중 오류가 발생했습니다: 디렉토리 접근 실패"
}

```

20. /prompt/session/get

기본 정보

항목	내용
Method	GET
URL	<code>/prompt/session/get</code>
설명	특정 세션의 내용 조회

요청 파라미터 (Query)

이름	필수	Type	설명
session_id	Y	String	조회할 세션 ID

요청 예시

```
curl -X GET "https://fai-rag.fingerservice.co.kr/prompt/session/get?session_id=user123_session"
```

성공 응답 예시

```
```json
{
 "session_id": "user123_session",
 "history": [
 {
 "role": "user",
 "message": "메타버스란 무엇인가요?",
 "timestamp": "2024-04-22T15:30:45.123Z"
 },
 {
 "role": "bot",
 "message": "메타버스는 가상과 현실이 융합된 디지털 공간입니다...",
 "timestamp": "2024-04-22T15:30:50.456Z"
 },
 {
 "role": "user",
 "message": "메타버스의 주요 기술은 무엇인가요?",
 "timestamp": "2024-04-22T15:31:20.789Z"
 },
 {
 "role": "bot",
 "message": "메타버스의 주요 기술로는 VR(가상현실), AR(증강현실), MR(혼합현실) 등이 있습니다...",
 "timestamp": "2024-04-22T15:31:25.123Z"
 }
],
 "created_at": "2024-04-22T15:30:40.000Z",
 "last_updated": "2024-04-22T15:31:25.123Z",
 "message_count": 4,
}
```

```
"exists": true
}
```

## 실패 응답 예시

```
{
 "error": "세션 ID가 필요합니다"
}
```

또는

```
{
 "error": "세션 내용 조회 중 오류가 발생했습니다: 세션 파일을 찾을 수 없음"
}
```

---

문서 업데이트 완료 – 필요 시 추가 요청 주세요.